

## Я поменял только обвязку. Счёт вырос в шесть раз

Я хотел выбрать кодинг-агента для себя, поэтому прогнал семь своих рабочих конфигураций на четырёх тяжёлых задачах. Все справились. А потом я посмотрел на цену: одна и та же GPT-5.6-sol обошлась в \$3,77, \$5,28 и \$23,06 в зависимости от harness.

### ЧТО Я ВЫБРАЛ

**Остаюсь на Codex. opencode держу как запасной вариант. omp после этого теста для меня закончился.**

На `gpt-5.6-sol medium` восемь прогонов стоили **\$3,77 в Codex**, **\$5,28 в opencode** и **\$23,06 в omp**. По сохранённым цифрам разница между omp и Codex равна **6,11×**. Из-за недосчитанного cache-write честнее говорить о диапазоне **5,38–6,11×**.

Все 56 прогонов прошли и видимые, и скрытые тесты. Это не доказывает, что агенты одинаково хороши. Просто на этих задачах качество никого не отсеяло, а цена отсеяла очень быстро.

### Что я гонял

Сначала в стенде было шесть лёгких задач. На них все выбивали 100%, и толку от такого сравнения не было. Я их выкинул и оставил четыре свои задачи, где нужно написать рабочую систему, а не поправить пару строк:

#### t7 · TS формулы

движок формул таблицы: токенайзер + парсер приоритетов + функции + строгая таксономия ошибок. 61+45 тестов.

#### t8 · PY запросы

движок запросов: filter→sort→distinct→paginate→project, строгая семантика типов. 29+22.

#### t9 · TS стек-VM

интерпретатор ассемблера: стек, переменные, метки, переходы, лимит шагов. 30+33.

#### t10 · PY cron

планировщик cron: разбор 5 полей, правило OR для dom/dow, следующие N срабатываний. 19+22.

Скрытые тесты ловят именно те решения, которые выглядят услужливо, но нарушают условие: коэрсят типы, читают неинициализированную переменную как ноль или путают OR с AND. Я заранее проверил, что такие варианты падают, а эталон проходит. Для t10 дополнительно сверил результат с независимым brute-force сканером на 24 расписаниях. Зависимости для grader не нужны: TS проверяется через `node --test` и `tsc`, Python — через `unittest`.

СЕМЬ СВЯЗОК

● codex56

Codex · 5.6-sol · med

дешевле всех

● codex55

Codex · 5.5 · high

● oc56

opencode · 5.6-sol · med

● oc55

opencode · 5.5 · high

● omp55

omp · 5.5 · high

● cscopus

Claude Code · opus-4.8 · xhigh

● omp56

omp · 5.6-sol · med

дороже всех

Все инструменты были на подписках. Доллары ниже — не списания с карты, а пересчёт по API-тарифам. Для Codex и opencode я считал input/cache-read/output по \$5/\$0,5/\$30 за миллион токенов. Cache-write стоит \$6,25/M, но отдельного счётчика не осталось, поэтому дешёвые колонки немного занижены. Отсюда диапазон 5,38–6,11x вместо красивого, но слишком точного 6,11x. Claude Code здесь для контекста: у него другая модель.

1. По тестам ничья: 56 из 56

Каждая связка дважды решила все четыре задачи и прошла скрытую проверку. Даже долгие прогоны, которые крутились по 15 минут, в итоге пришли к правильному ответу.


|           | t7 формулы | t8 запросы | t9 VM | t10 cron |
|-----------|------------|------------|-------|----------|
| ● codex56 | ✓✓         | ✓✓         | ✓✓    | ✓✓       |
| ● codex55 | ✓✓         | ✓✓         | ✓✓    | ✓✓       |
| ● oc56    | ✓✓         | ✓✓         | ✓✓    | ✓✓       |
| ● oc55    | ✓✓         | ✓✓         | ✓✓    | ✓✓       |
| ● omp55   | ✓✓         | ✓✓         | ✓✓    | ✓✓       |
| ● omp56   | ✓✓         | ✓✓         | ✓✓    | ✓✓       |
| ● cscopus | ✓✓         | ✓✓         | ✓✓    | ✓✓       |

На этих 56 прогонах правильность никого не разделила. Я не делаю из этого вывод, что harness одинаково хороши вообще.

## 2. Цена: здесь разница уже огромная

| ЗАДАЧА             | CODEX56 | CODEX55 | OC56 | OC55 | OMP55 | CCOPUS | OMP56 |
|--------------------|---------|---------|------|------|-------|--------|-------|
| t7 формулы         | 1,36    | 1,82    | 1,47 | 2,04 | 3,23  | 5,68   | 6,72  |
| t8 запросы         | 0,80    | 1,09    | 1,24 | 1,16 | 1,72  | 2,68   | 5,81  |
| t9 VM              | 0,75    | 0,75    | 1,05 | 1,31 | 3,81  | 2,13   | 5,02  |
| t10 cron           | 0,86    | 1,11    | 1,51 | 0,99 | 2,82  | 2,75   | 5,51  |
| Итого · 8 прогонов | 3,77    | 4,77    | 5,28 | 5,50 | 11,58 | 13,24  | 23,06 |

Зелёным отмечен самый дешёвый результат на задаче. Везде это Codex.



Сумма за восемь прогонов. Codex и opencode немного недосчитаны по cache-write, но даже самая жёсткая поправка оставляет между omp56 и Codex минимум 5,38х.

## 3. Дорогие связки заодно оказались медленными

В первой версии я вообще убрал время: решил, что параллельный запуск сделал его бесполезным. Потом всё-таки посчитал. Порядок семи связок почти полностью совпал с порядком по цене, Pearson r = 0,986. Но у Codex часть времени восстановлена по таймстемпам, поэтому одну соседнюю пару нельзя честно расставить по местам.

| ЗАДАЧА · СЕК (ПРОГОН 1 / ПРОГОН 2) | CODEX56    | CODEX55    | OC56      | OC55      | OMP55     | CCOPUS    | OMP56      |
|------------------------------------|------------|------------|-----------|-----------|-----------|-----------|------------|
| t7 формулы                         | 213 / 244° | 254 / 292° | 204 / 205 | 327 / 339 | 371 / 311 | 905 / 705 | 508 / 1153 |
| t8 запросы                         | 75 / 102°  | 104 / 111° | 172 / 248 | 193 / 172 | 149 / 163 | 346 / 390 | 591 / 810  |
| t9 VM                              | 126 / 95   | 121 / 114  | 125 / 166 | 192 / 170 | 277 / 395 | 174 / 212 | 650 / 173  |
| t10 cron                           | 169 / 124  | 138 / 225  | 200 / 290 | 160 / 138 | 193 / 469 | 359 / 343 | 794 / 394  |
| Итого · 8 прогонов, мин            | 19,1°      | 22,6°      | 26,8      | 28,2      | 38,8      | 57,2      | 84,5       |

° — время восьми ячеек Codex на t7/t8 пришлось восстановить по таймстемпам рабочих каталогов: scratchpad из /private/tmp уже исчез. Такая реконструкция занижает результат. На ячейках, где остались оба источника, разница составляла 10–65 секунд, в среднем 40. Поэтому 55% времени codex56 и 56% времени codex55 — не прямой замер. Плюс все прогоны шли параллельно (–P4/–P6), так что абсолютные секунды немного шумят.

0,986

корреляция цены и времени; шесть мест из семи выдерживают поправку

\$0,20–0,30

примерная цена минуты в этих прогонах

4,4×

Codex — 19 минут, opencode — 27, omp — 85 на одной модели

Я не утверждаю, что время само по себе определяет цену. Скорее оба показателя растут из-за длинных агентных циклов. Но секундомер оказался полезным сигналом: если агент работает в четыре раза дольше, счёт тоже, скорее всего, будет неприятным.

ЧТО БУДЕТ, ЕСЛИ ПОПРАВИТЬ ВРЕМЯ CODEX

Я добавил к каждой восстановленной ячейке сначала среднюю ошибку, потом максимальную:


- Без поправки все семь мест совпадают с ценой.
- При +40 секундах на ячейку порядок не меняется.
- При +65 секундах codex55 и oc56 меняются местами с разницей в девять секунд.

Итого: шесть мест из семи устойчивы. Кто быстрее между codex55 и oc56, этот тест не доказал. Зато крупные разрывы никуда не деваются: omp56 работает больше чем в четыре раза дольше Codex, Claude Code с Opus — примерно втрое.


4. Одна модель, три обвязки

Ради этого сравнения я и затевал весь тест. Модель и effort одинаковые, меняется только harness. Все задачи решены, но цена расходится в разы.

GPT-5.6-SOL · MEDIUM — ТА ЖЕ МОДЕЛЬ, 8 ПРОГОНОВ



GPT-5.5 · HIGH — ТА ЖЕ МОДЕЛЬ, 8 ПРОГОНОВ



Обе шкалы нарисованы в одном масштабе. Для 5.6 medium разница между Codex и omp лежит где-то между 5,38× и 6,11×. Нижняя граница уже включает максимально невыгодную поправку cache-write для Codex.

ОМР ДОРОЖЕ НА КАЖДОЙ ЗАДАЧЕ, А НЕ ТОЛЬКО В СУММЕ

| ЗАДАЧА     | CODEX  | OPENCODE | OMP     | OMP / CODEX |
|------------|--------|----------|---------|-------------|
| t7 формулы | \$1,36 | \$1,47   | \$6,72  | 4,92×       |
| t8 запросы | \$0,80 | \$1,24   | \$5,81  | 7,25×       |
| t9 VM      | \$0,75 | \$1,05   | \$5,02  | 6,69×       |
| t10 cron   | \$0,86 | \$1,51   | \$5,51  | 6,44×       |
| итого      | \$3,77 | \$5,28   | \$23,06 | 6,11×       |

Во всех строках одна модель: `gpt-5.6-sol medium`. Отношения 4,9–7,3× немного завышены из-за cache-write у Codex. По сумме после предельной поправки остаётся 5,38×.

5. Дело не только в болтливости

Я сначала подумал, что дорогие агенты просто печатают больше текста. Не сходится. Если вычесть стоимость output tokens, основная разница всё равно остаётся.

| СВЯЗКА  | \$ ВСЕГО | \$ OUTPUT | NON-OUTPUT RESIDUAL | ДОЛЯ RESIDUAL | OUTPUT TOKENS |
|---------|----------|-----------|---------------------|---------------|---------------|
| codex56 | 3,77     | 1,70      | 2,07                | 55%           | 56 741        |
| ос56    | 5,28     | 1,32      | 3,96                | 75%           | 43 962        |
| сcopus  | 13,24    | 5,12      | 8,12                | 61%           | 204 874       |
| omp56   | 23,06    | 2,97      | 20,09               | 87%           | 99 067        |

Residual — итоговая оценка минус стоимость выходных токенов. Разложить остаток на свежий input, чтение и запись кэша, служебный контекст и число ходов уже нельзя: этих счётчиков нет.

Лучше всего это видно на codex56 и ос56. opencode напечатал на 23% меньше токенов, чем Codex: 43 962 против 56 741. При этом его оценка на 40% выше. Значит, длина ответа разницу не объясняет.


У omp56 выходные токены стоят только \$2,97 из итоговых \$23,06. Остальные \$20,09, то есть 87%, сидят в части, которую сохранённый датасет уже не умеет разложить.

ДАЖЕ ПОРЯДОК МОДЕЛЕЙ ЗАВИСИТ ОТ HARNESS

В omp профиль 5.6 medium стоит \$23,06, почти вдвое дороже 5.5 high за \$11,58. В Codex всё наоборот: 5.6 medium дешевле 5.5 high, \$3,77 против \$4,77. Здесь одновременно меняются модель и effort, поэтому причину я не изолировал. Но практический вывод простой: нельзя выбрать «дешёвый профиль» отдельно от harness.

## 6. Если уйду с Codex, пойду в opencode

opencode оказался хорош. По цене и скорости он рядом с Codex, а выходных токенов выдаёт меньше всех. Если я перестану пользоваться моделями GPT или Claude, то спокойно перееду сюда: подписка opencode Go за \$10 даёт доступ к основным open source моделям. После поправки cache-write разница с Codex может ещё сократиться. Оба всё равно очень далеко от omp.



Выходные токены за восемь прогонов. opencode самый короткий. Claude Code с Opus напечатал примерно в 4,5 раза больше, хотя тесты прошли все.

## 7. Где я ошибся и что в данных неполно

### CODEX НЕ ПРЫГАЛ ПО ЦЕНЕ. ЭТО БЫЛ МОЙ КРИВОЙ ЗАПУСК

В прошлом черновике я написал, что цена codex56 скачет от \$0,6 до \$3,1. Оказалось, флаг `-c mcp_servers={}` не отключал MCP из глобального конфига. Подвисавший `exa` раздувал отдельные сессии в 2–6 раз. Я вынес Codex в отдельный чистый `CODEX_HOME` и переснял всё заново. После этого codex56 оказался самым ровным и дешёвым.

- Изоляция.** Codex работал с чистым `CODEX_HOME` без MCP, opencode — с `--pure`, omp — с `--no-lsp` через `openai-codex`. Реальных web/MCP-вызовов в прогонах не было.
- Цена.** Codex и opencode пересчитаны по общей формуле  $\$5/\$0,5/\$30$ . Cache-write недосчитан. omp отдаёт свою цену, у opencode в OAuth-логах она нулевая. Ошибочный fallback \$0,125 для одной ячейки я заменил на \$0,4479: одни только выходные токены там стоят \$0,1596.
- Автономность.** Все 56 прогонов прошли headless и ни разу не спросили человека. Каждый агент сам дошёл до зелёных тестов.
- Время.** Я зря убрал его из первой версии. Крупные разрывы переживают и параллельный запуск, и ошибку реконструкции. Но 55% итогового времени codex56 восстановлено, а не замерено напрямую.
- Выборка.** Четыре задачи и два прогона — это личный срез, а не доказательство на все случаи. Я доверяю разнице в разы. Мелкие дельты здесь ничего не значат. Effort не выровнен, потому что я сравнивал свои реальные конфигурации.

## Что делаю по итогу

- **Codex остаётся моим рабочим инструментом.** Когда вендор делает и модель, и harness под неё, это видно. Связка Codex + GPT быстрая, экономная и просто работает.
- **opencode — запасной аэродром.** Если придётся слезть с иглы Codex + GPT, я уже знаю куда идти: opencode Go за \$10 и open source модели.
- **omp оказался переоценённой хутой.** У меня нет более аккуратной формулировки. Конфигурация 16.5.2 с gpt-5.6 medium проиграла на каждой задаче и по цене, и по времени. Это вывод ровно про протестированную конфигурацию, но для моей рутины вопрос закрыт.
- **Claude Code с Opus — дорого и долго.** Даже с xhigh effort. Для сравнения, Codex на GPT-5.5 high отрабатывал заметно быстрее. Из-за другой модели это не чистый тест harness, но выбирать эту связку для себя я не стал.

---

Окружение: OpenAI Codex v0.144.4 · opencode 1.17.17 · omp 16.5.2 · Claude Code v2.1.210 · Node 26.5.0 · Python 3.14.6 · TS 5.9.3. 56 прогонов (7 связок × 4 задачи × 2), метрики восстановлены из логов харнессов (ssusage-codex + пересчёт по токенам, claude-json, потоки событий opencode/omp). Это не рейтинг продуктов, а мой выбор инструмента на моём стеке. В репозитории лежат задачи t7–t10 и датасет с цифрами. Разброс 6,11× — верхняя граница; с максимально невыгодной поправкой cache-write остаётся 5,38×.